

矩阵和向量空间

模型里，数据的基本表示形式

小胖

目录

ONE 矩阵的定义

标量、向量和矩阵

TWO 矩阵的运算

加减乘除

THREE 向量空间

向量内积和特征向量

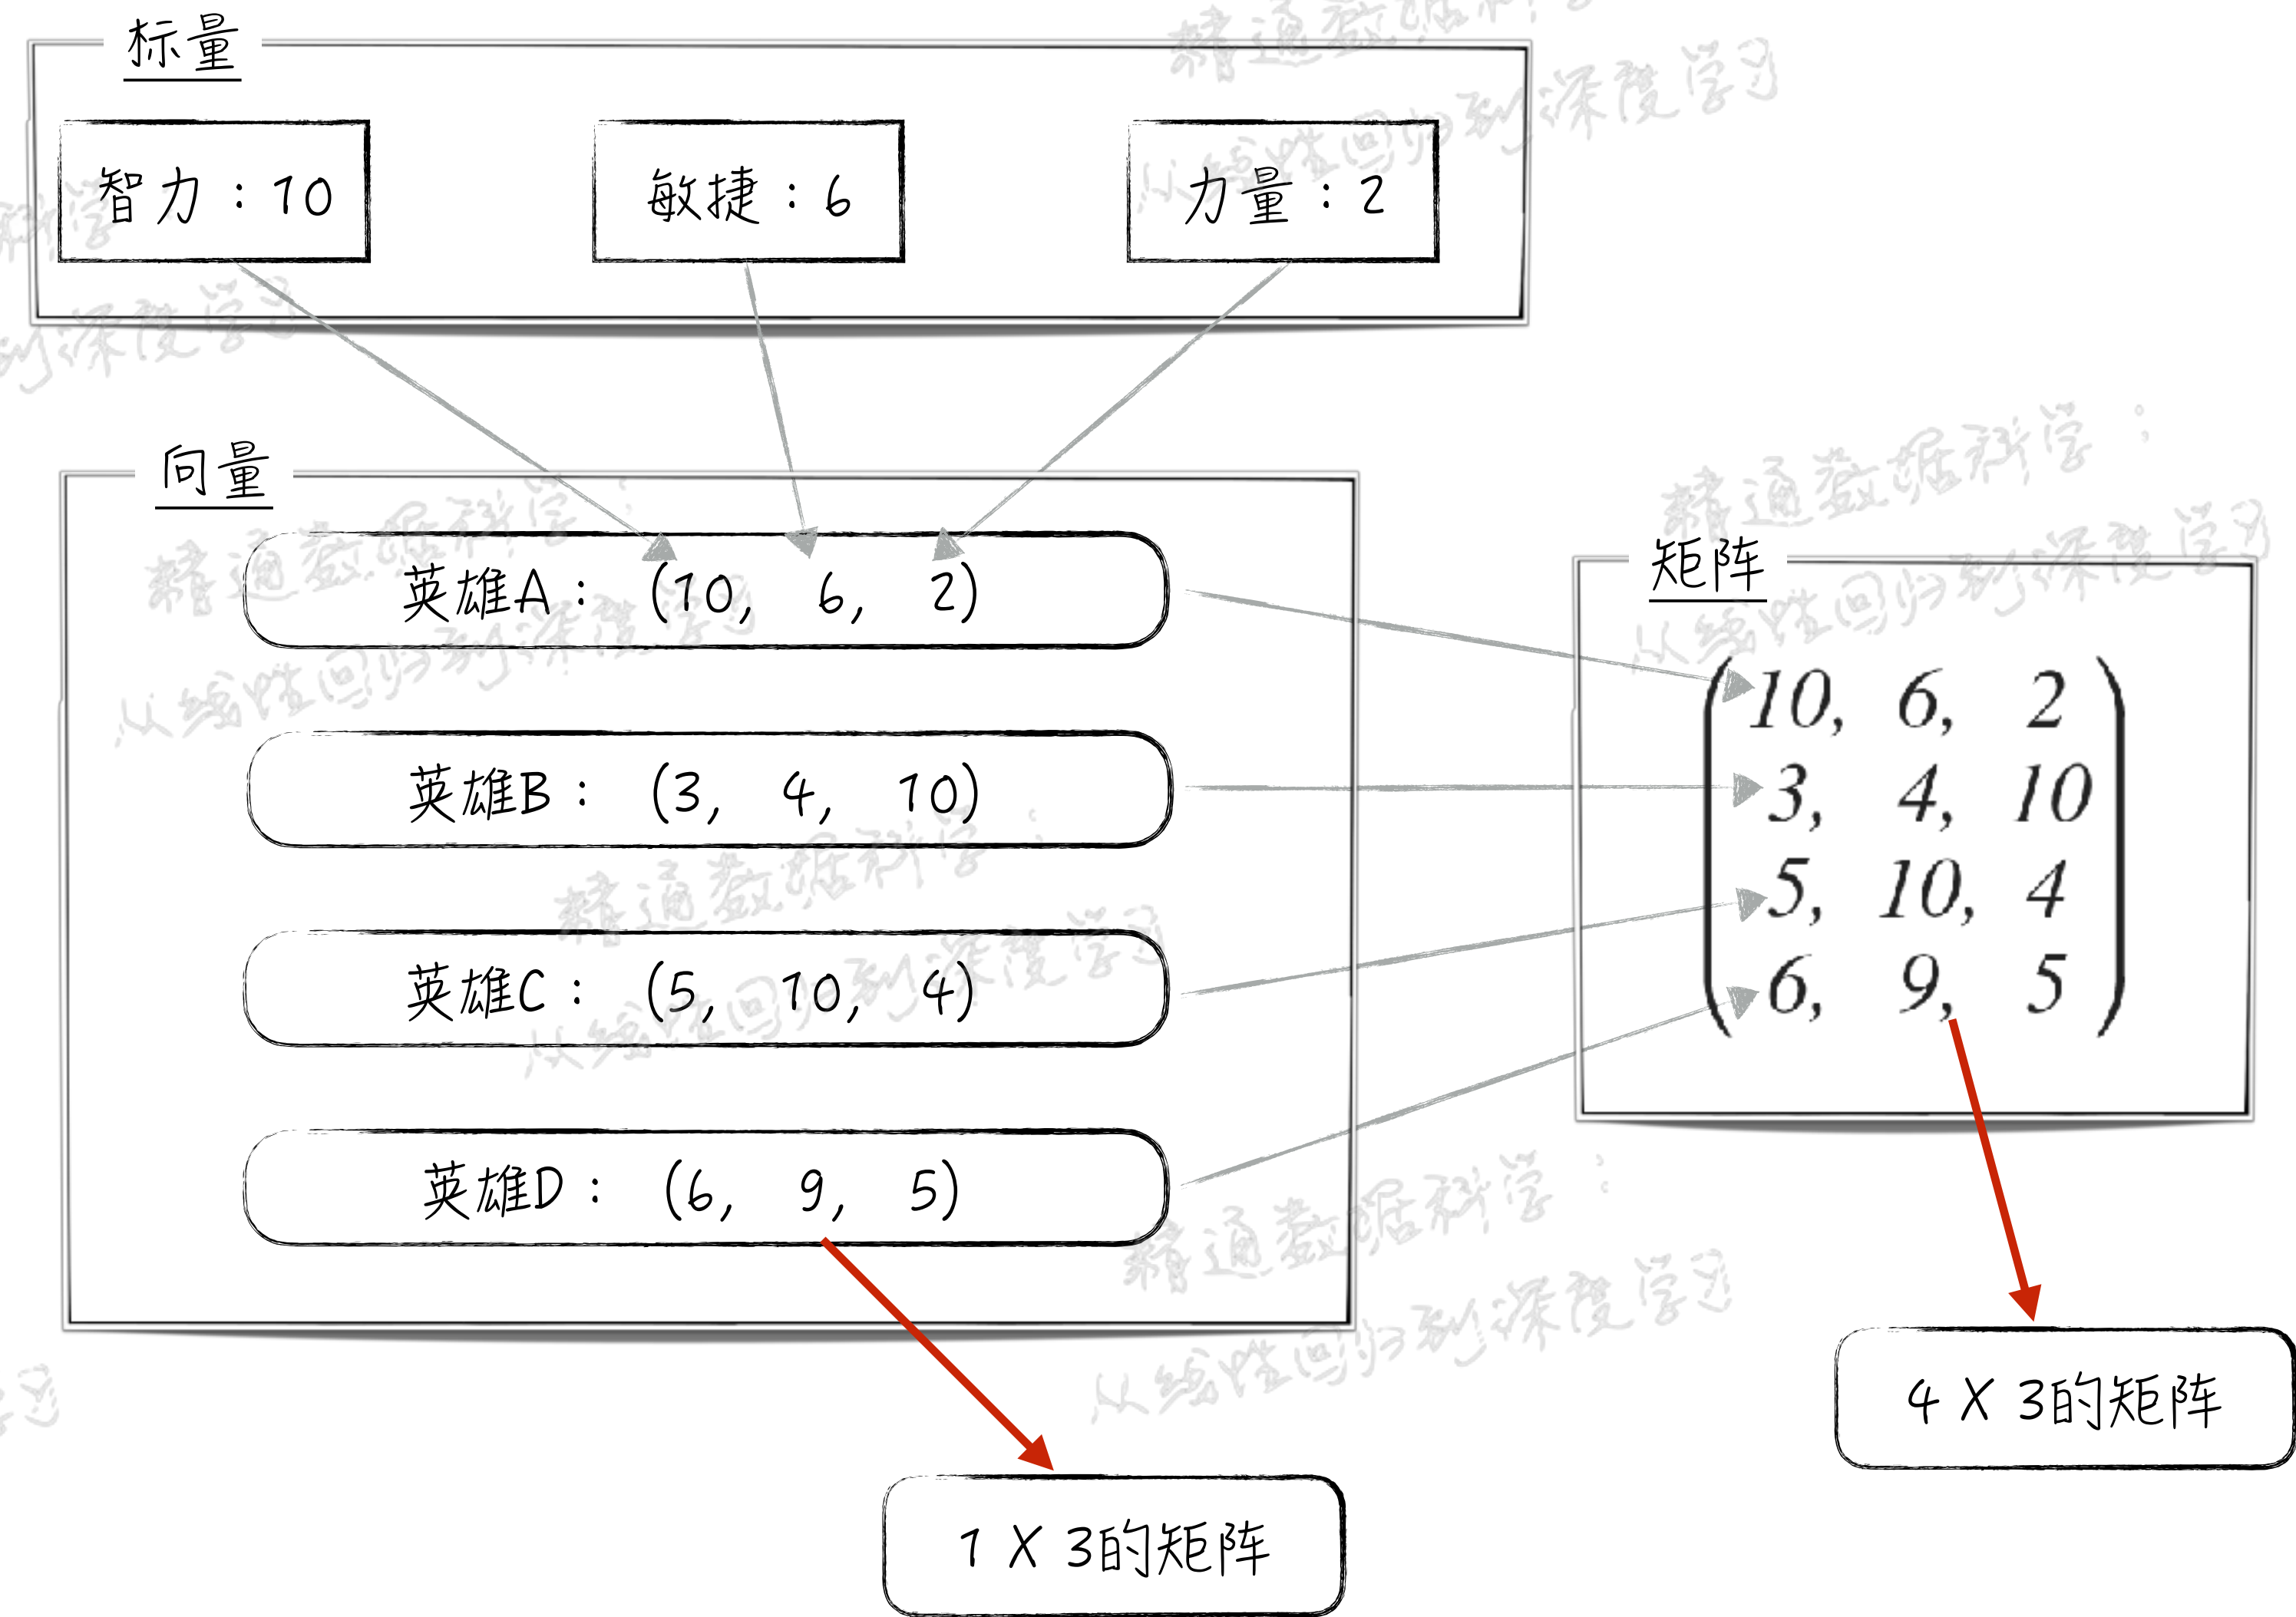
如果有人不相信数学是简单的，那是因为他们没有
意识到人生有多复杂

矩阵的定义

标量、向量和矩阵

想象一款网络游戏

- 它用智力、敏捷和力量这三个属性来客户英雄

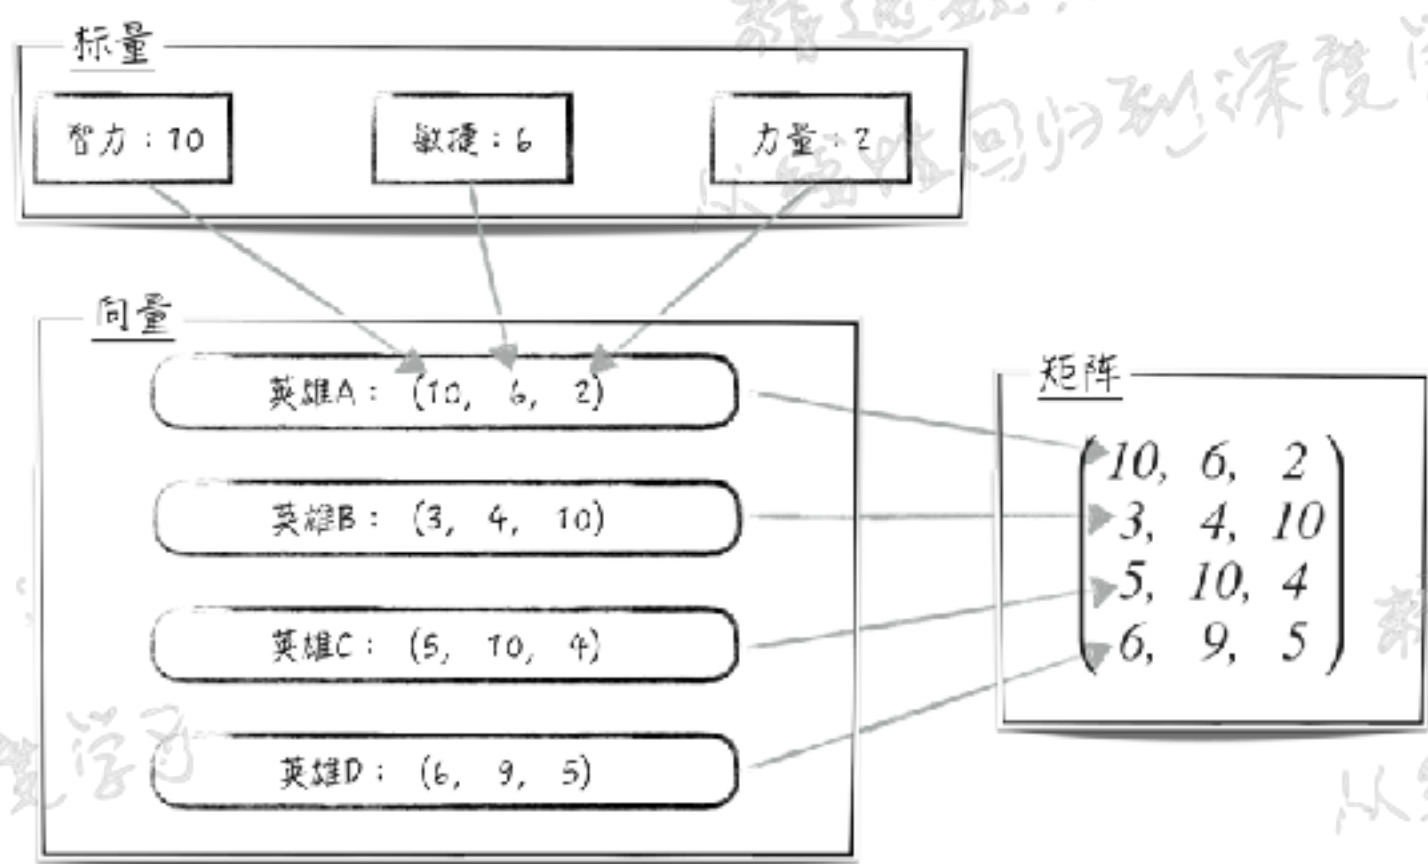


矩阵的定义

标量、向量和矩阵

在数学上，通常

- 使用 $x_{i,j}$ 来表示标量
- 使用 X_i 来表示向量
- 使用 X 来表示 $n \times m$ 的矩阵



标量、向量和矩阵的关系如下

在数学上，通常

- 使用 $R^{n \times m}$ 来表示 $n \times m$ 的矩阵全体

$$X_i = (x_{i,1}, x_{i,2}, \dots, x_{i,m})$$
$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} = (x_{i,j}) \in \mathbf{R}^{n \times m}$$

矩阵的定义

特殊矩阵

单位矩阵

$$I_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} = (1_{\{i=j\}}) \in \mathbf{R}^{n \times n}$$

对角矩阵

$$\text{diag}(d_1, d_2, \dots, d_n) = \begin{pmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{pmatrix} \in \mathbf{R}^{n \times n}$$

三角矩阵

$$L = \begin{pmatrix} l_{1,1} & 0 & \cdots & 0 \\ l_{2,1} & l_{2,2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n,1} & l_{n,2} & \cdots & l_{n,n} \end{pmatrix} \in \mathbf{R}^{n \times n} \quad U = \begin{pmatrix} u_{1,1} & u_{1,2} & \cdots & u_{1,n} \\ 0 & u_{2,2} & \cdots & u_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{n,n} \end{pmatrix} \in \mathbf{R}^{n \times n}$$

目录

ONE 矩阵的定义

标量 向量和矩阵

TWO 矩阵的运算

加减乘除

THREE 向量空间

向量内积和特征向量

矩阵的运算

加法、减法

矩阵可以看作是一些实数的某种排列，因此，
我们希望将实数的四则运算延续到矩阵上。

两个矩阵的行数和列数相同

矩阵的加减法：
要求两个矩阵的形状是一样的

矩阵加法满足
加法交换律和结合律

$$\mathbf{X} = (x_{i,j}) \in \mathbf{R}^{n \times m}; \mathbf{Y} = (y_{i,j}) \in \mathbf{R}^{n \times m}$$
$$\mathbf{X} \pm \mathbf{Y} = \begin{pmatrix} x_{1,1} \pm y_{1,1} & \cdots & x_{1,m} \pm y_{1,m} \\ \vdots & & \vdots \\ x_{n,1} \pm y_{n,1} & \cdots & x_{n,m} \pm y_{n,m} \end{pmatrix} = (x_{i,j} \pm y_{i,j}) \in \mathbf{R}^{n \times m}$$

$$\mathbf{X} + \mathbf{Y} = \mathbf{Y} + \mathbf{X}$$
$$\mathbf{X} + \mathbf{Y} + \mathbf{Z} = \mathbf{X} + (\mathbf{Y} + \mathbf{Z})$$

矩阵的运算

矩阵的乘法

有关矩阵的乘法可以分为两种：


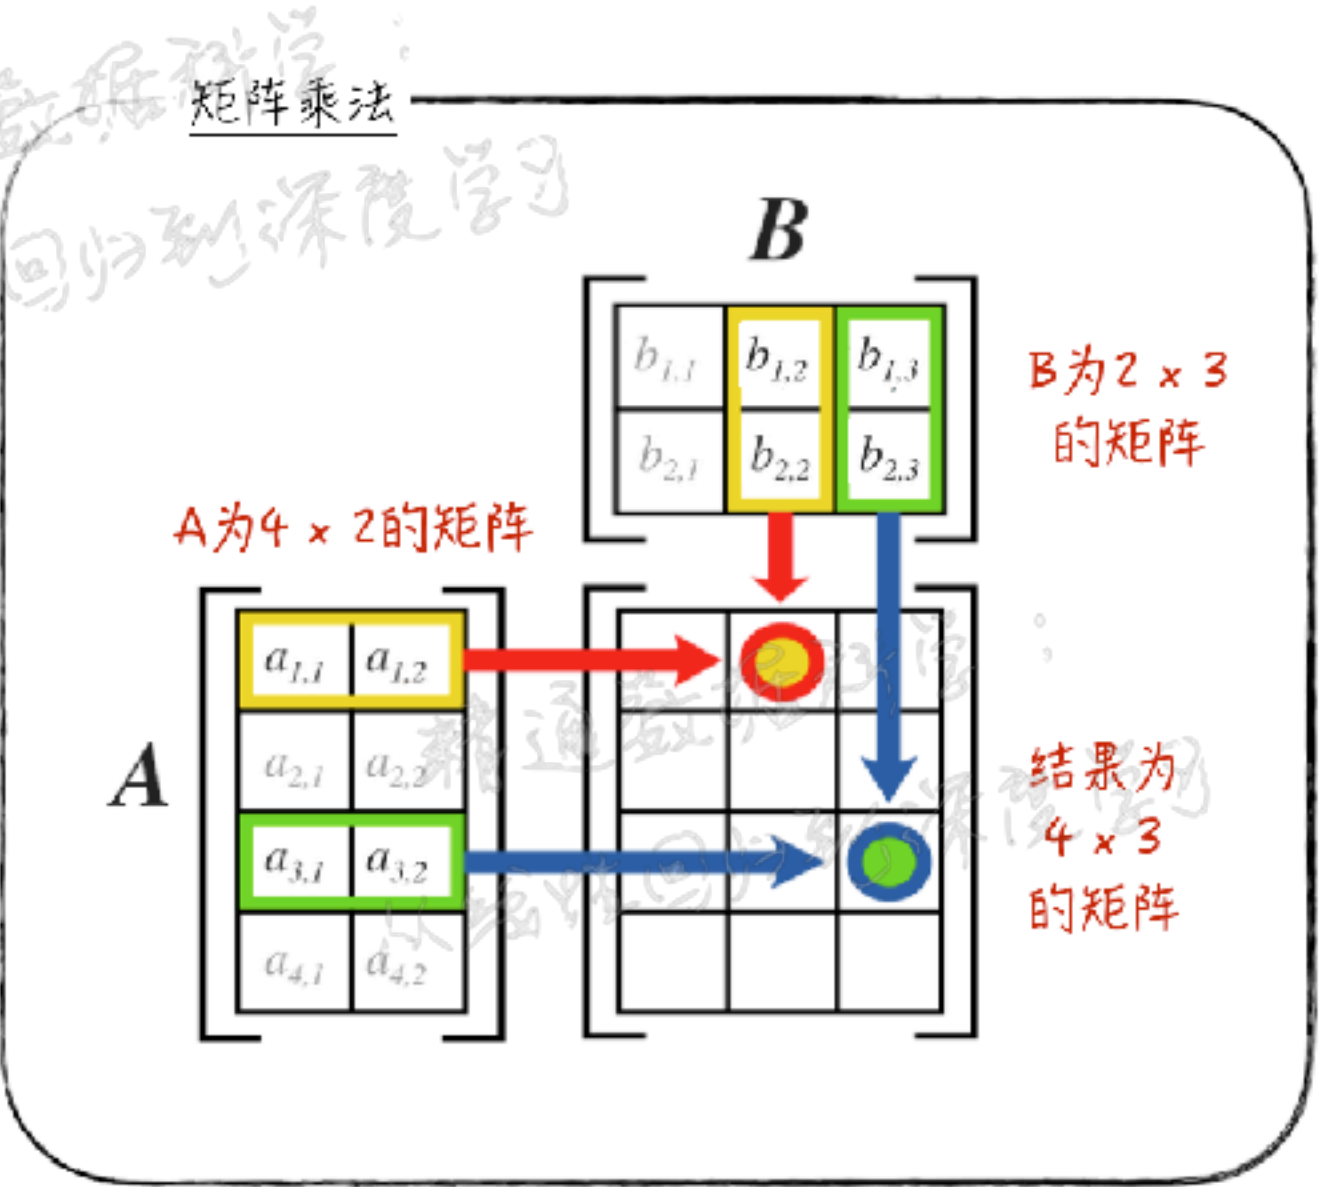
- 矩阵与数字的乘法
- 矩阵与矩阵的乘法

矩阵与数字的乘法很简单

$$kX = \begin{pmatrix} kx_{1,1} & \cdots & kx_{1,m} \\ \vdots & & \vdots \\ kx_{n,1} & \cdots & kx_{n,m} \end{pmatrix} = (kx_{i,j}) \in \mathbf{R}^{n \times m}$$

矩阵与矩阵的乘法有两种：

- 矩阵乘法
- Hadamard乘法

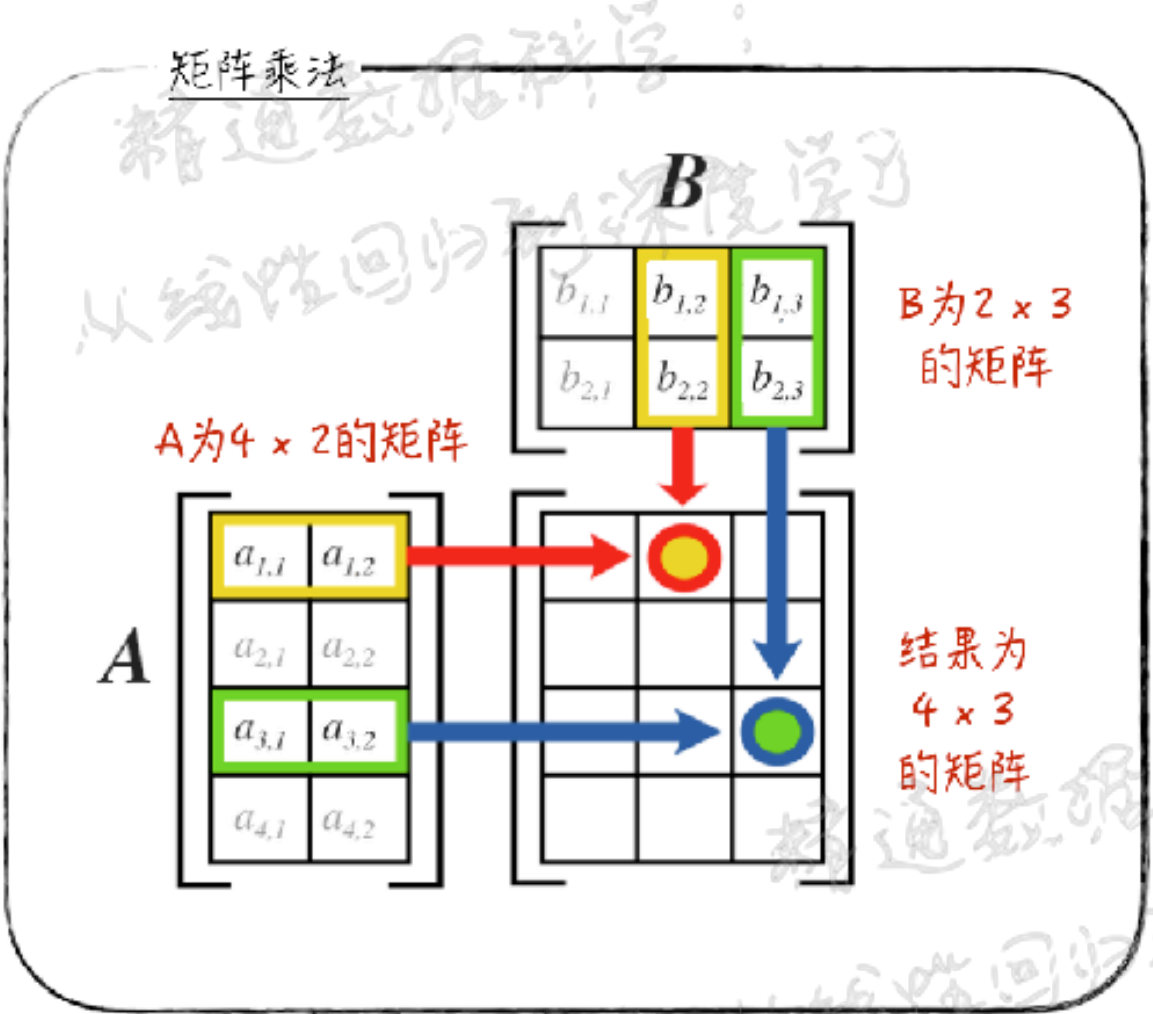


矩阵的运算

矩阵的乘法

矩阵乘法要求
第一个矩阵的列数 = 第二个矩阵的行数

$$A = (a_{i,j}) \in \mathbf{R}^{n \times p}; B = (b_{i,j}) \in \mathbf{R}^{p \times m}$$
$$AB = (\sum_{r=1}^p a_{i,r} b_{r,j}) \in \mathbf{R}^{n \times m}$$




矩阵乘法满足
结合率和分配律

$$(AB)C = A(BC)$$
$$A(B + C) = AB + AC$$

矩阵的Hadamard乘法要求
两个矩阵的形状一样

$$A \circ B = (a_{i,j} b_{i,j}) \in \mathbf{R}^{n \times m}$$



矩阵乘法可以极大地
简化模型的表示和计算

$$\begin{cases} y_1 = ax_1 + b \\ y_2 = ax_2 + b \end{cases}$$

令 $X = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \end{pmatrix}$, $\beta = \begin{pmatrix} a \\ b \end{pmatrix}$, $Y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$

$$Y = X\beta$$

矩阵的运算

逆矩阵和转置

逆矩阵的定义只针对 $n \times n$ 的方阵

如果对于方阵 M ,
存在方阵 N 满足

$$MN = NM = I_n$$

则称 N 为 M 的
逆矩阵, 记为

$$N = M^{-1}$$

容易证明, 逆矩阵如
果存在, 则逆矩唯一。
并且有如下的性质:

$$\begin{aligned}(M^{-1})^{-1} &= M \\ (kM)^{-1} &= \frac{1}{k} M^{-1} \\ (MN)^{-1} &= N^{-1} M^{-1}\end{aligned}$$

这是课后
习题

对于一个 $n \times m$ 的矩阵, 它的转置是一个 $m \times n$ 的矩阵

具体的定义十分简单

$$\begin{aligned}X &= (x_{i,j}) \in \mathbf{R}^{n \times m} \\ X^T &= (x_{j,i}) \in \mathbf{R}^{m \times n}\end{aligned}$$

容易证明

$$\begin{aligned}(X^T)^T &= X \\ (X + Y)^T &= X^T + Y^T \\ (kX)^T &= kX^T \\ (XY)^T &= Y^T X^T \\ (X^T)^{-1} &= (X^{-1})^T\end{aligned}$$

定义对称矩阵:

$$X^T = X$$

目录

ONE 矩阵的定义

标量、向量和矩阵

TWO 矩阵的运算

加减乘除

THREE 向量空间

向量内积和特征向量

向量空间

内积定义


抛开严谨的数学定义，向量空间可以认为是线性变换下保持封闭的空间，比如我们生活的三维空间

任意一个三维行向量都能表示成 $e_1=(1,0,0)$ 、 $e_2=(0,1,0)$ 和 $e_3=(0,0,1)$ 的线性组合

- 这三个向量在一起组成了三维行向量空间的一组**正交基**
- 任意三个相互正交的三维行向量都是三维行向量空间的一组**正交基**
- 这个结论可以推广到n维行向量空间


我们生活的三维空间里，任何一点都能被一个三维行向量表示

向量空间



向量空间

内积定义



内积等于零

两向量正交

定义两个向量的内积为


$$A \cdot B = a_1 b_1 + a_2 b_2 + a_3 b_3$$
$$A \cdot B = AB^T$$

如果B的长度为1

A和B的内积等于A在B上的投影长度

向量空间

特征向量和特征值



$$X = \begin{pmatrix} A \\ B \\ C \end{pmatrix}$$

A、B、C到直线W
的投影平方和

$$\|Xw^T\|^2$$

$$v = \operatorname{argmax}_{\|w\|=1} \|Xw^T\|^2 = \operatorname{argmax}_{\|w\|=1} wX^T Xw^T$$

现在假设二维空间中有一些点，希望找到一条直线，使得这些点到这条直线的距离平方和最小

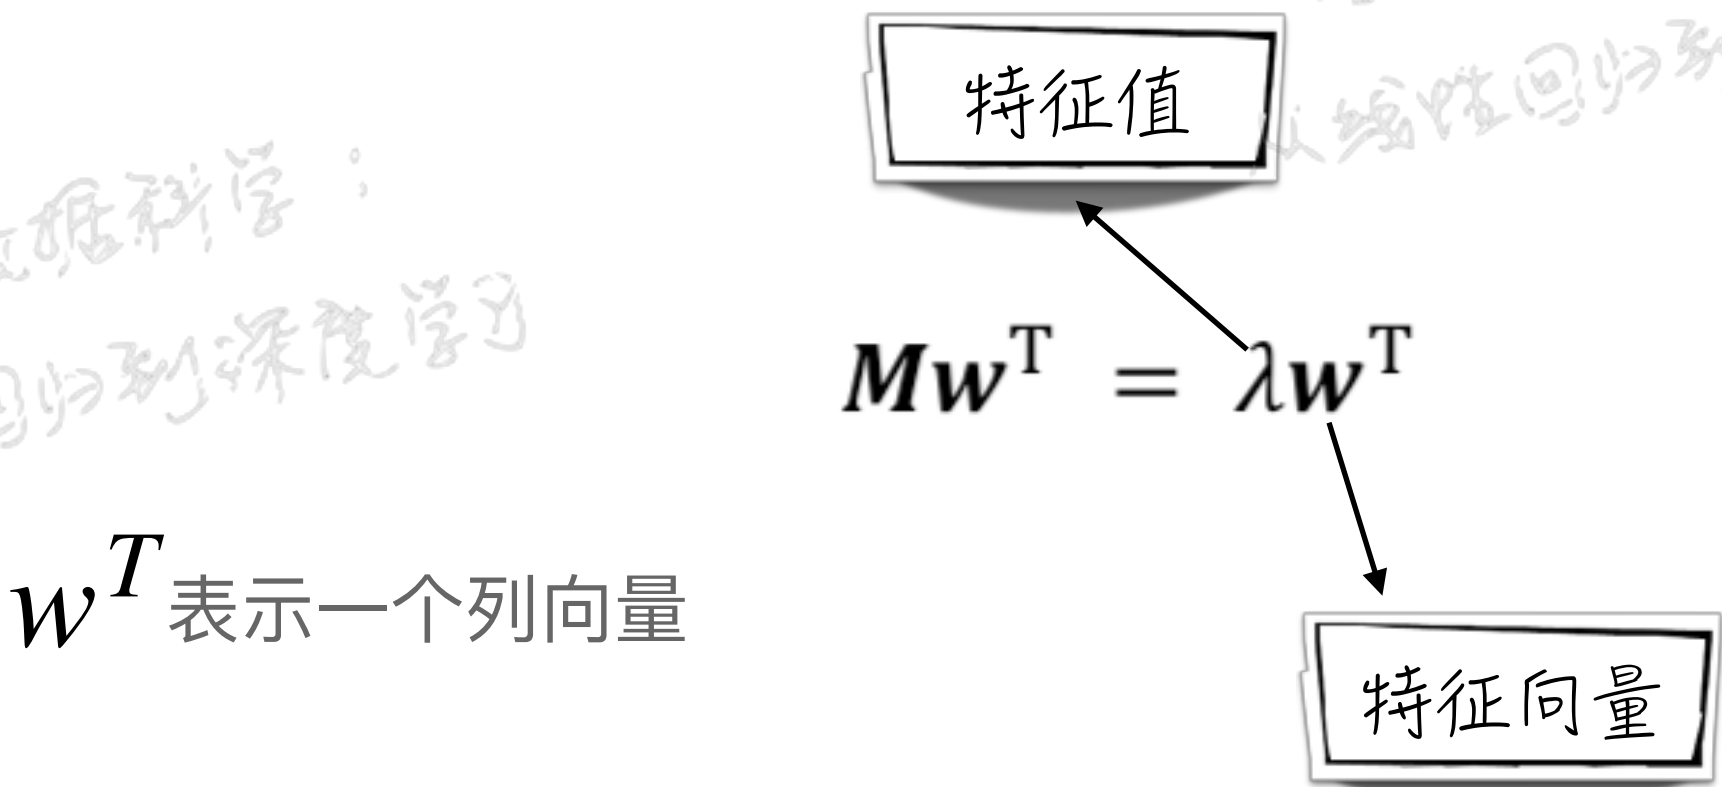
- 距离平方和最小意味着投影平方和最大

注意到 $K = X^T X$ 是一个对称矩阵，为了解决上面这个问题，我们需要引入特征向量 (eigenvector) 和特征值 (eigenvalue) 这两个概念

向量空间

特征向量和特征值

对于一个矩阵M，如果下面的公式成立，
则特征向量和特征值定义如下：



对于n阶的对称矩阵，存在n个相互正交的特征矩阵。

矩阵 $K = X^T X$ 最大特征值对应的
特征向量就是我们要找的v

$$v = \operatorname{argmax}_{\|w\|=1} \|Xw^T\|^2 = \operatorname{argmax}_{\|w\|=1} wX^T Xw^T$$

最大特征值对应的
特征向量

这是课后
习题

精通数据科学；
从线性回归到深度学习

THANK YOU